
UNIVERSIDAD DEL NORTE SANTO TOMÁS DE AQUINO

FACULTAD DE INGENIERÍA

INFORME DE ANÁLISIS DE KPI'S

Taller I – Desafío Strata

Integrantes:

Castillo Upton, Patricio Sebastián

Nieva Pastoriza, Ana Belén

Pachado, Felipe Antú

Rebora, Juan Pablo

Docente: Ana Martínez Saucedo

Fecha de entrega: 08/10/2025

Resumen Ejecutivo

Este informe técnico presenta el diseño e implementación de un **pipeline de datos en la nube de AWS**.

El documento describe la **arquitectura de la solución**, los **procesos ETL implementados** y los **principales resultados obtenidos** durante el proyecto.

Con el objetivo de **analizar el comportamiento de los usuarios y optimizar las campañas de marketing**, se construyó un proceso **automatizado y escalable** que integra y transforma información proveniente de cuatro fuentes principales:

- **DNA:** datos de clientes,
- **RCHG:** registros de recargas,
- **ADJ:** compras de paquetes, y
- **NPS:** encuesta de satisfacción mensual.

El pipeline combina los servicios **Amazon S3**, **AWS Glue** y **AWS Lambda** para realizar la **ingesta, transformación y automatización de los datos**.

Esto permitió garantizar la **calidad, consistencia y trazabilidad** de la información a lo largo del proceso.

Introducción

La implementación de buenas prácticas de **DataOps** en este proyecto permitió aplicar principios de **DevOps al ciclo de vida de los datos**, con el fin de **agilizar la entrega de valor analítico** y **asegurar la calidad y disponibilidad** de la información.

Este enfoque posibilita convertir los pipelines tradicionales en procesos **automatizados** (no se automatizó, ya que se trabajó con una base de datos estática, de “prueba”), **monitorizados y reproducibles**, reduciendo el tiempo entre la **obtención de un dato** y su **análisis final**.

Los principales objetivos del proyecto fueron:

1. **Automatizar** el flujo completo de ingesta y transformación de datos.
2. **Asegurar la calidad e integridad** mediante validaciones automáticas.
3. **Diseñar un sistema escalable y de bajo mantenimiento** aprovechando servicios gestionados en la nube.

La solución se implementó sobre **Amazon Web Services (AWS)**, utilizando:

- **Amazon S3** como *data lake centralizado*,
- **AWS Glue** para la ejecución de procesos **ETL visuales y programáticos**, y
- **AWS Lambda** para la **conversión de archivos csv a parquet** para un procesamiento de datos más eficiente.

Este enfoque permitió construir una infraestructura eficiente, flexible y confiable, alineada con los principios de **DataOps**, optimizando el acceso a información precisa y oportuna para la toma de decisiones estratégicas.

Descripción del proyecto

Arquitectura Utilizada

La arquitectura implementada se basa en un enfoque **serverless** dentro del ecosistema de **Amazon Web Services (AWS)**, utilizando servicios totalmente gestionados que permiten automatizar el flujo de datos sin necesidad de administrar servidores.

Los principales componentes son:

1. Amazon S3

Actúa como el **repositorio central de datos** y se estructura en diferentes carpetas o zonas. Permite la integración directa con otros servicios como Glue y Lambda mediante **eventos y triggers**.

2. AWS Lambda

- Es el componente encargado de la **automatización y orquestación** del flujo.
- También puede realizar **validaciones rápidas**, mover archivos entre carpetas o enviar **notificaciones** al completar una tarea.


3. AWS Glue

- Es el servicio principal de **procesamiento y transformación de datos (ETL)**.
- Permite la construcción de flujos mediante el entorno **visual de AWS Glue Studio** o mediante **scripts en Python o SQL**.
- Puede realizar tareas de:
 - Limpieza y normalización de datos.
 - Unión de fuentes y cálculo de métricas o agregaciones.
 - Conversión de formatos (por ejemplo, CSV a Parquet).
- Los resultados se guardan nuevamente en S3.

Diagrama de Arquitectura

Descripción general de los diagramas:

1. **Amazon S3:** Almacena los datasets iniciales (**RECARGAS**, **DNA**, **ADJ**), provenientes de diferentes fuentes.
2. **AWS Glue Studio:** Orquesta el proceso ETL mediante un flujo visual compuesto por:
 - **Limpieza:** eliminación de valores nulos (**Remove Null Rows**) y duplicados (**Drop Duplicates**).
 - **Filtrado y agregación:** uso de nodos SQL y transformaciones para calcular clientes únicos, cantidades por semana.
 - **CROSS JOIN y cálculos porcentuales:** combinación de datasets semanales con totales para generar información.
 - **Transformación personalizada:** uso de nodos *Custom Transform* para aplicar lógica adicional.
3. **Amazon S3 (zona curada):** almacenamiento de los resultados procesados y listos para análisis o visualización.



Flujo de Trabajo

El flujo de datos sigue los siguientes pasos:

1. **Carga de datos en S3:**

Los archivos fuente son depositados en el bucket S3, dentro de la carpeta correspondiente a cada dataset (**RECARGAS**, **DNA**, **ADJ**).

2. **Procesamiento en AWS Glue:**

- Se leen los tres datasets de S3.
- Se aplican pasos de limpieza (eliminación de nulos y duplicados).
- Se ejecutan consultas SQL para calcular métricas semanales (**numero_semana**, clientes por semana, totales, etc.).
- Los resultados se combinan mediante operaciones **CROSS JOIN** y se calculan **porcentajes** de compra/recarga por semana.

3. **Salida y almacenamiento:**

Los resultados finales se escriben nuevamente en **S3**, dentro de la carpeta destino, listos para su análisis.

Lenguajes y herramientas

Durante el desarrollo del flujo de trabajo en AWS Glue se utilizaron los siguientes lenguajes y herramientas:

SQL (Structured Query Language):

Se empleó para realizar consultas y transformaciones dentro de AWS Glue Visual ETL.

Un ejemplo de código utilizado fue:

```
SELECT

Numero_de_semana,

Cantidad_por_semana,

Total_clientes

FROM semanales

CROSS JOIN totales;
```

- Esta consulta permitió combinar los resultados semanales con los totales de clientes, generando una vista consolidada de los datos.

Otra consulta realizada fue:

```
SELECT

Numero_semana,


Clientes_por_semana,

Total_clientes,

ROUND((Clientes_por_semana * 100.0 / Total_clientes), 2) AS
porcentaje_clientes

FROM crossjoin
```

- Esta instrucción permitió calcular el **porcentaje de clientes por semana** en relación al total general, generando un indicador de rendimiento útil para el análisis posterior.



Flujo de Trabajo

El flujo de datos para el cálculo del NPS sigue los siguientes pasos:

1. Carga de datos en S3:

Los archivos fuente (`Sample\_Satisfaccion202504`) son depositados en un bucket S3, transformados a formato Parquet y catalogados manualmente en AWS Glue para evitar errores de permisos del Crawler.

2. Procesamiento en AWS Glue:

El proceso ETL se diseñó en un único Job visual para obtener los porcentajes de lealtad:

- **Ramificación y Clasificación:** El dataset de encuestas se divide en tres ramas que utilizan nodos Filter para segregar a los clientes en Promotores (≥ 9), Neutros (7 y 8) y Detractores (≤ 6).
- **Etiquetado y Estandarización:** Cada rama utiliza el nodo Derived Column para asignar la etiqueta ('Promotor', 'Neutros', 'Detractor') y el nodo ApplyMapping para garantizar que los tres esquemas de salida sean idénticos.
- **Unión y Conteo:** Las tres ramas se consolidan mediante nodos Union encadenados. Un nodo Aggregate posterior cuenta los clientes por segmento.
- **Cálculo del Total:** Se genera una rama paralela para obtener el Total de Encuestados mediante un Aggregate (sin agrupación) y un ApplyMapping para renombrar la columna a `Total_Encuestados`.
- **Unión para el Cálculo:** Los resultados del Conteo por Segmento y del Total se combinan mediante un nodo Inner Join (utilizando una clave dummy simulando un Cross Join), adjuntando el `Total_Encuestados` a cada fila de segmento.

3. Salida y almacenamiento:

El resultado final, que incluye la columna con el porcentaje calculado, se escribe nuevamente en S3, dentro de la carpeta destino, listo para el cálculo del NPS () y el uso en herramientas de BI.

Lenguajes y Herramientas

Durante el desarrollo del flujo de trabajo en AWS Glue se utilizaron el Visual ETL y el Lenguaje de Expresiones de Spark (similar a SQL) para las transformaciones clave:


Lenguaje de Expresiones de Spark:

Se empleó para la lógica condicional y las operaciones matemáticas dentro del nodo Derived Column (Columna Derivada), que es donde se ejecuta la transformación del porcentaje.

El indicador de rendimiento clave calculado fue: Porcentaje de clientes por segmento

La instrucción utilizada fue: $(\text{Conteo_Segmento} / \text{Total_Encuestados}) * 100$

Esta instrucción permitió calcular el porcentaje de clientes por segmento en relación al total general de encuestados, generando un indicador de rendimiento esencial para el análisis posterior y el cálculo del NPS.



Flujo de Trabajo

1. Entrada de Datos

- AWS Glue toma la metadata desde el **Data Catalog** y accede a los datos crudos almacenados en un bucket S3 o base de datos registrada.

2. Limpieza y Preparación

- Se eliminan registros nulos (incompletos).
- Se eliminan duplicados para asegurar calidad en el dataset.

3. Enriquecimiento

- Se generan columnas derivadas (ejemplo: calcular márgenes, clasificaciones, etc.).
- Se aplican filtros para quedarse solo con los datos relevantes.

4. Transformaciones Avanzadas

- Se realizan agregaciones (ejemplo: ventas totales por región).
- Se aplican transformaciones personalizadas en PySpark para casos complejos.

5. Selección de Datos

- Se selecciona el dataset resultante de todas las transformaciones.

6. Salida de Datos

- El dataset procesado se carga en un bucket de **Amazon S3**, listo para análisis o consumo por otros servicios.

Metodología de trabajo

Columna Identificadora Principal para relacionar buckets

- **Atributo clave:** *accs_mthd_cd*.
- **Descripción:** Esta columna representa el identificador único de cada cliente o método de acceso. Se utilizó como **columna fundamental para enlazar datos** y relacionar entre sí todos los archivos de origen (compra de paquetes, datos del cliente, recargas y encuesta de satisfacción).

Manejo de Duplicados

El tratamiento de duplicados dependía directamente del KPI que se deseaba calcular.

Tratamiento de nulos

Se realizó una limpieza de nulos basada en el descarte de filas y columnas nulas, así como la falta de fecha o *accs_mthd_cd*. Posteriormente, en el conteo para los KPI's, se contó en base a la columna *accs_mthd_cd*, por lo que cualquier nulo no sería contado.

Realización de KPI's

• "Porcentaje de clientes que recargaron por semana":

- **Fuente:** Registros de tipo *RCHG* (Recargas).
- **Columnas/Criterios para identificar un duplicado:** Se consideraron duplicadas la entradas cuya combinación de *accs_mthd_cd* y *day_key* es idéntica en el mismo periodo de tiempo. Esto significa que si un cliente realizó múltiples recargas en el mismo día, solo fue contado una vez para el KPI de "clientes únicos que recargaron por semana".
- **Tratamiento:** Se eliminaron los duplicados del flujo ETL para este KPI, más no de los buckets originales, basándose en la combinación de *accs_mthd_cd* y *day_key* para obtener una lista de clientes únicos por día. Luego, se agruparon por semana para el conteo final.
- **Justificación:** El objetivo es contar la cantidad de *clientes individuales* que hicieron una recarga, no el número de transacciones de recarga.

• "Porcentaje de clientes que compraron packs por semana":

- **Fuente:** Registros de tipo *ADJ* (Packs).
- **Columnas/Criterios para identificar un duplicado:** Se consideraron duplicadas la entradas cuya combinación de *accs_mthd_cd* y *day_key* es idéntica en el mismo periodo de tiempo. Esto significa que si un cliente realizó múltiples compras en el mismo día, solo fue contado una vez para el KPI de "clientes únicos que compraron packs por semana".
- **Tratamiento:** Se eliminaron los duplicados del flujo ETL para este KPI, más no de los buckets originales, basándose en la combinación de *accs_mthd_cd* y *day_key* para obtener una lista de clientes únicos por día. Luego, se agruparon por semana para el conteo final.
- **Justificación:** El objetivo es contar la cantidad de *clientes individuales* que hicieron compraron packs, no el número de transacciones de recarga.

- **“Monto promedio de recargas semanales”:**

- **Fuente:** Registros de tipo *RCHG* (Recargas).
- **Columnas/Criterios para identificar un duplicado:** No se eliminarán duplicados para este KPI.
- **Tratamiento:** Se realizó una sumatoria de la columna *rchrg_amt* del bucket completo de recargas. Todas las transacciones de recarga, incluso si un mismo cliente realiza varias en un día, contribuyeron al monto total. Posteriormente, se filtraron por semana y se promediaron.
- **Justificación:** Cada transacción de recarga aporta un valor monetario al total, y el objetivo es cuantificar ese valor acumulado.

- **“NPS” y “Cantidad de promotores, neutros y detractores”:**

- **Fuente:** Registros de tipo *Sample Satisfaction* (Encuestas de satisfacción).
- **Columnas/Criterios para identificar un duplicado:** Columna clave: *accs_mthd_cd* (Identificador único de cliente/línea).
- **Tratamiento:** Se creó la columna *Segmento_NPS* (Detractor: 0-6; Neutro: 7-8; Promotor: 9-10). Luego se contó la cantidad de clientes por segmento.
- **Justificación:** El NPS se calcula como la diferencia entre el porcentaje de Promotores y el porcentaje de Detractores ($NPS = \%Promotores - \%Detractores$). La clasificación de cada cliente encuestado es el paso inicial y obligatorio para el cálculo.

- **“% de detractores, neutros y promotores en el mes de la encuesta realizada”:**

- **Fuente:** Registros de tipo *Sample Satisfaction* (Encuestas de satisfacción).
- **Columnas/Criterios para identificar un duplicado:** Se asume que el archivo *Sample_Satisfaccion202504.csv* tiene una fila por cliente encuestado.
- **Tratamiento: Cálculo de Proporción.** El proceso de ETL visual unió el conteo de cada segmento con el conteo Total de Encuestados usando un Join Cartesiano simulado. Finalmente, se usó una Derived Column para calcular el porcentaje: $Total_Encuestados / Conteo_Segmento \times 100$.
- **Justificación:** Se requiere el porcentaje de cada grupo para entender la distribución de la lealtad de la base de clientes. El total de clientes encuestados es necesario como denominador para calcular la proporción de cada segmento.

Análisis de KPI's

- “NPS” y “Cantidad de promotores, neutros y detractores”:

Conteo_Segmento ▾	Total_Encuestados ▾	segmento_nps ▾	Porcentaje_Segmento ▾
78	300	Neutros	26
102	300	Detractor	34
120	300	Promotor	40

El indicador principal de este análisis es la columna **Porcentaje_Segmento**, que permite visualizar la proporción de cada grupo de lealtad en relación con el total de clientes encuestados.

La columna **Conteo_Segmento** representa un conteo numérico de la cantidad de personas en cada sección de la columna **segmento_nps**.

El campo **Porcentaje_Segmento** muestra la distribución de la base de clientes, donde se observa que los segmentos más grandes son el de Promotores (40%) y el de Detractores (34%). Este alto porcentaje de Detractores casi iguala a los Promotores (la base más leal), resultando en un NPS Final de 6.00.

Este indicador de NPS de 6.00 es un valor positivo, pero indica una lealtad muy débil en la base de clientes. La salud del KPI se considera frágil, ya que la gran cantidad de clientes activamente insatisfechos (34%) casi anula por completo el impacto positivo de la base de Promotores. Además, el 26% de clientes Neutros representa un segmento significativo que está abierto a la competencia, lo cual añade vulnerabilidad al negocio.

- “Porcentaje de clientes que compraron un pack por semana”:

Numero_semana ↓	Clientes_por_semana ↑↓	Total_clientes ↑↓	porcentaje_clientes ↑↓
18	461	4995	9.23
17	1339	4995	26.81
16	1471	4995	29.45

La columna **número de semana** y sus valores hacen referencia al rango de tiempo filtrado, se cuentan semanas calendario, por lo que semana 16 corresponde a la tercera semana de abril (14 a 20 del mes), 17 a la cuarta, y 18 a la quinta. A su vez, la columna **clientes por semana**

nos indica la cantidad de clientes que realizaron una recarga en el período de tiempo establecido. Por último, la columna **total de clientes** expresa la cantidad de clientes registrados en la base de datos.

El campo **porcentaje** permite visualizar la evolución de la participación semanal de clientes, donde se observa que durante las semanas 16 y 17 del año 2025 los valores se mantuvieron estables -entre 26,81% y 29,45%-, mientras que en la semana 18 se produjo una caída significativa al 9,23%, lo cual puede indicar una disminución temporal en la actividad o bien puede ser explicada por la disponibilidad de solo dos archivos de registros en esa semana.

- **“Porcentaje de clientes que recargaron por semana”:**

Numero_de_semana	Cientes_por_semana	Total_clientes	porcentaje_clientes
18	203	4995	4.06
17	1423	4995	28.49
16	1427	4995	28.57

La columna **número de semana** y sus valores hacen referencia al rango de tiempo filtrado, se cuentan semanas calendario, por lo que semana 16 corresponde a la tercera semana de abril (14 a 20 del mes), 17 a la cuarta, y 18 a la quinta. A su vez, la columna **clientes por semana** nos indica la cantidad de clientes que realizaron una recarga en el período de tiempo establecido. Por último, la columna **total de clientes** expresa la cantidad de clientes registrados en la base de datos.

El campo **porcentaje** permite visualizar la evolución de la participación semanal de clientes, donde se observa que durante las semanas 16 y 17 del año 2025 los valores se mantuvieron estables (alrededor del 28,5%), mientras que en la semana 18 se produjo una caída significativa al 4,06%, lo cual puede indicar una disminución temporal en la actividad o bien puede ser explicada por la disponibilidad de solo **un** archivo de registros en esa semana.

- “Monto promedio de recargas semanales”:

numero_semana ↑↓	Monto_semanal_rch ↑↓	cant_clientes_rch ↑↓	monto_promedio_por_cliente ↑↓
1	9843.02	1806	5.45
2	8826.86	1647	5.36

La columna **numero_semana** hace referencia al rango de tiempo filtrado. Se contabilizan **semanas calendario**, de modo que la semana 1 corresponde al primer período analizado dentro del conjunto de datos. Por otro lado, el monto_semanal_rch representa el monto total en **dólares** de las recargas efectuadas durante la semana correspondiente. La **cant_clientes_rch** indica la **cantidad total de clientes** que realizaron al menos una recarga dentro del período semanal. Y por último el **monto_promedio_por_cliente** expresa el **promedio de gasto por cliente**, que permite comparar el comportamiento de consumo entre semanas.

En la **semana 1**, se registró un **monto total de 9.843,02 dólares** con **1.806 clientes**, obteniendo un promedio de **5,45 dólares por cliente**.

En la **semana 2**, el monto total fue de **8.826,86 dólares** con **1.647 clientes**, resultando en un promedio ligeramente menor (**5,36 dólares por cliente**).

Estos resultados evidencian una **disminución tanto en el monto total recargado como en la cantidad de clientes**, lo cual podría estar asociado a **variaciones en el comportamiento de consumo, promociones puntuales o factores estacionales**.

El análisis permite evaluar la **evolución del rendimiento comercial semanal**, identificando posibles **tendencias de consumo o fluctuaciones temporales** en la actividad de los usuarios.

Desempeño del sistema

El flujo de trabajo se ejecutó correctamente en **AWS Glue Visual ETL**, con una duración promedio de **entre 1 y 2 minutos**, dependiendo del tamaño de los datos procesados.

El procesamiento resultó eficiente gracias al uso del formato **Parquet**, que optimiza la lectura y escritura de datos en operaciones analíticas. Además, Glue administró automáticamente los recursos de cómputo necesarios (nodos de ejecución), manteniendo un buen equilibrio entre **rendimiento y coste**.

Desafíos y soluciones

Durante la implementación del proceso en AWS, se presentaron diversos desafíos relacionados con la integración, automatización y manejo de datos en los servicios **S3, Glue y Lambda**.

A continuación, se detallan los principales problemas encontrados y las soluciones aplicadas.

- Las transformaciones complejas no siempre podían resolverse desde la interfaz visual de Glue Studio, especialmente en casos que requerían expresiones condicionales o cálculos personalizados.
- Tiempos de ejecución elevados en ciertos procesos de transformación, especialmente al trabajar con grandes volúmenes de datos.
- Fallos aleatorios y aparentemente sin razón en el desarrollo del ETL visual, como nodos que dejan de funcionar, entre otras cosas. No tuvo una solución clara.

Soluciones:

- Se integraron **scripts en Python y SQL** dentro de los nodos de Glue Studio, combinando la facilidad del entorno visual con la flexibilidad del código.
- Se optimizaron los trabajos mediante:
 - Conversión de archivos a formato **Parquet** (columnar y comprimido).

Conclusiones

El desarrollo del proceso ETL en **AWS Glue** permitió comprender de manera práctica los principios de **DataOps** y su aplicación dentro de un entorno de **computación en la nube**. A través de la implementación del flujo de datos desde la carga de archivos en **Amazon S3** hasta las transformaciones y consultas SQL en Glue se logró automatizar la obtención, procesamiento y análisis de información de manera eficiente y escalable.

Durante el proyecto, adquirimos una visión integral sobre cómo los servicios de **AWS** se integran entre sí para conformar un ecosistema de datos moderno. En particular, se comprendió la flexibilidad del **Visual ETL** para diseñar flujos sin necesidad de programación extensa, y la utilidad de **Lambda** para la automatización de tareas, a pesar de no ser implementada. Además, se fortalecieron habilidades en **SQL**, **Python**, y en la interpretación de flujos de datos dentro de arquitecturas distribuidas.

Desde el punto de vista del trabajo en equipo, la experiencia fomentó la **colaboración**, la **división de tareas** y la **comunicación efectiva**, aspectos fundamentales en proyectos de ingeniería de datos y DataOps, donde la coordinación y la trazabilidad son claves para mantener la calidad del producto final.

Cabe destacar que parte del análisis técnico y las decisiones de diseño se realizaron con la asistencia del modelo GPT-5 de OpenAI, utilizado como herramienta de apoyo pedagógico para la estructuración del flujo ETL, principalmente para la resolución de dudas de forma espontánea y eficaz, actuando como un tutor personal.

Como sugerencias para futuros proyectos, se recomienda:

- Incorporar **mayor automatización** mediante el uso de **triggers** o **workflows** de AWS Glue.
- Implementar **pruebas de validación de datos** y **monitoreo continuo** para mejorar la confiabilidad del pipeline.
- Documentar de forma más detallada cada paso del proceso para facilitar la **reproducibilidad** y **mantenimiento** del flujo.
- Explorar herramientas adicionales del ecosistema AWS, como **Athena** o **QuickSight**, para enriquecer el análisis y la visualización de resultados.
- Mejorar la distribución de tareas y los tiempos de acción en los grupos de trabajo

Bibliografía

- Google. (2025). Gemini (Versión 1.5 Pro del modelo de lenguaje). Google.
- OpenAI. (2025). *Asistencia técnica y resolución de dudas sobre procesos DataOps y AWS Glue*. ChatGPT (versión GPT-5) [Modelo de lenguaje]. OpenAI. <https://chat.openai.com/>

El siguiente bloque de referencias corresponde al contenido técnico y bibliográfico utilizado por el modelo de lenguaje GPT-5 (ChatGPT, OpenAI) como base de conocimiento para brindar asistencia técnica, conceptual y metodológica durante la elaboración del presente trabajo. El modelo fue empleado como herramienta de apoyo para la búsqueda, integración y explicación de información técnica, actuando como un “superbuscador” especializado en DataOps y AWS.

- *What is AWS Glue?* - AWS Glue. (s. f.). <https://docs.aws.amazon.com/glue/latest/dg/what-is-glue.html>
- *Analytics on AWS*. (s. f.). Amazon Web Services, Inc. <https://aws.amazon.com/big-data/datalakes-and-analytics/>
- *Amazon Simple Storage Service (S3) Documentation*. (s. f.). Amazon Web Services, Inc. <https://docs.aws.amazon.com/s3/>
- *Analytics on AWS*. (s. f.-b.). Amazon Web Services, Inc. <https://aws.amazon.com/big-data/datalakes-and-analytics/>